


Analyse comparative des techniques de data mining pour l'évaluation de la performance prédictive de la probabilité de défaut chez les clients détenteurs de cartes de crédit

Présenté par:

- Frank ONANA TSANGA
- Cabrel SADJUE KWENDJI
- Merieme BASSAOUI
- Naouel YOUSFI
- Thierry YOUM ESEMTSOU


Enseignant: Daniel Yapi

Session: Hiver 2026




Plan de la présentation

- Contexte et Problématique étudiée
- Méthodologie
- Résultats
- Etude comparative et discussion



Contexte : la crise du crédit à Taïwan



Impact majeur :

- Perte de confiance dans le système financier
- Difficultés pour les banques et les consommateurs

Pourquoi la gestion du risque est essentielle?



Gestion du risque de crédit

Gestion de crise → **réactive** (après le problème)

Prédiction du risque → **préventive** (avant le défaut)



Objectif


Anticiper le **risque de défaut**
Réduire les pertes et l'incertitude



Données utilisées

informations financières
comportements de paiement
historiques de transactions

Outils de prédiction du risque



Modèles Classiques

Analyse discriminante


Régression logistique

Classificateurs bayésiens

k plus proches voisins (KNN)

Réseaux de neurones artificiels

Arbres de classification



Sorting Smoothing Method (SSM)

Comparer la **performance de classification** de 6 techniques

Évaluer la **qualité des probabilités de défaut estimées**

Méthodologie:

Jeu de données

- 30 000 clients (avril–septembre 2005)
- 23 variables dont 14 variables numériques et 9 variables catégorielles
- Variable cible : défaut le mois suivant (22,12 %)

Algorithmes utilisés dans l'article:

K plus proches voisins, Régression logistique, Analyse discriminante ,
Algorithme bayésien naïf , Réseaux neuronaux , Arbres de classification

Notre approche

Prétraitement

- Variables qualitatives → one-hot encoding
- Variables quantitatives → normalisées (min-max)

Implémentation Forêt aléatoire, SVM et XGBOOST en plus des
algorithmes de l'article

Evaluation des modèles:

Pour évaluer les performances de classification binaire (défaut / non-défaut), les auteurs utilisent :

- ✓ Le taux d'erreur issu de la matrice de confusion
- ✓ La courbe ROC et l'aire sous la courbe (AUC)
- ✓ Le lift chart (courbe de gain cumulatif)



Evaluation des modèles: Sorting Smoothing Method (SSM)

- ✓ La méthode consiste à utiliser la probabilité de défaut réelle (Y) comme variable réponse et la probabilité de défaut prédite (X) comme variable indépendante, puis à ajuster une régression linéaire simple ($Y = A + BX$)
- ✓ Le meilleur modèle est celui pour lequel :
 - A (intercept) est le plus proche de 0
 - B (pente) est le plus proche de 1
 - Le coefficient de détermination R^2 est le plus élevé

Évaluation des modèles avec Lift Chart

LIFT CHART

Objectif :

- Mesurer le pouvoir discriminant
- Comparer la performance du modèle par rapport à un choix purement aléatoire.

Étape	Action	Rôle
1. Tri	<code>argsort(-y_score)</code>	Classer les clients du plus "à risque" au moins "à risque".
2. Cumul	<code>np.cumsum</code>	Calculer le % de défauts détectés à mesure qu'on avance dans la liste.
3. Baseline	Diagonale	Représenter le hasard (ex: cibler 10% des gens capte 10% des défauts)
4. Idéal	<code>best_curve</code>	Le "modèle parfait" qui placerait 100% des défauts au tout début.
5. Ratio	Indice de Gini	Score final entre 0 et 1 (Aire modèle / Aire idéale).

Évaluation des modèles avec Lift Chart

RESULTATS DE ARTICLE




Figure 3.1: Graphe de lift pour KNN




Figure 3.2: Graphe de lift pour RL




Figure 3.3: Graphe de lift pour Analyse Discriminante




Figure 3.4: Graphe de lift pour Naïve Baise




Figure 3.5: Graphe de lift pour Réseau de Neurones






Figure 3.6: Graphe de lift pour Arbre de Classification

Évaluation des modèles avec Lift Chart


**NOTRE
ANALYSE**




Évaluation des modèles avec le SSM




1. KNN




2. Régression logistique




3. Analyse Discriminante



4. Naïve Bayes



5. Réseau de Neurones



6. Arbre de classification

Évaluation des modèles avec le SSM

SSM vérifie dans quelle mesure les probabilités prédites suivent la tendance des probabilités réelles estimés

Comment le SSM évalue-t-il les modèles?

Bon modèle présente en général:

- Un coefficient de régression proche de 1
- Un intercept proche de 0
- R^2 élevé presque égal à 1, pour mesurer l'ajustement

Résultats du SSM

- Comparaison des méthodes

Méthode	Coeff.	Intercept	R ²
KNN	0.770	0.0522	0.876
Régression logistique	1.233	-0.0523	0.794
Analyse discriminante	0.837	-0.1530	0.659
Naïve Bayes	0.502	0.0901	0.899
Réseau de neurones	0.998	0.0145	0.965
Arbre de Classification	1.111	-0.0276	0.278

- Réseaux de neurones : $R^2 = 0,965$, soit la meilleure qualité d'ajustement.
- Naïve Bayes et KNN obtiennent de bonnes performances.
- Les arbres de classification affichent le R^2 le plus faible (0,278).

Selon le SSM, les réseaux de neurones présentent la meilleure performance

Comment notre analyse se distingue des résultats de l'article de 2009 ?

1) Prétraitement des données

- Encodage des variables catégorielles
- Normalisation des données

2) Algorithmes

- Reprises des 6 algorithmes
- Ajout de 3 algorithmes (SVM, Xgboost, Random Forest)